




영화 흥행 요인 분석

데이터 전처리 · EDA · 모델링

Movie Success Analysis



분석 과정



사용 데이터와 분석 변수

movies_metadata.csv

예산 · 매출 · 러닝타임 · 장르 · 개봉
일 등 영화 기본 정보

모델 입력변수 4개

- 제작비 (log_budget)
- 러닝타임 (runtime)
- 대표 장르 (main_genre)
- 개봉 계절 (season)

links.csv

MovieLens movieId와 TMDb id를 올바르게 연결하는 매핑 파일

(Example)

movie= 'Heat'

➔ movies_metadata.id = 949

➔ ratings_small.movieId = 6

➔ links.csv

movieId 6 -> tmdbId 949

목표 변수

- 회귀: 로그 매출 (log_revenue)
- 분류: 매출 상위 25% 여부 (high_revenue)

전처리 ① 데이터 로드 · 자료형 정리

숫자 계산이 가능하도록 ID, 예산, 매출, 러닝타임을 수치형으로 변환

핵심 처리

- ① id / budget / revenue / runtime을 숫자로 변환
- ② id가 없는 행 제거
- ③ 중복 TMDb id 제거

```
movies = pd.read_csv(
    r'C:\Users\pjybe\Downloads\archive_extracted\movies_metadata.csv',
    low_memory=False)
ratings = pd.read_csv(
    r'C:\Users\pjybe\Downloads\archive_extracted\ratings_small.csv')
links = pd.read_csv(
    r'C:\Users\pjybe\Downloads\archive_extracted\links.csv')

movies['id'] = pd.to_numeric(movies['id'], errors='coerce')
movies['budget'] = pd.to_numeric(movies['budget'], errors='coerce')
movies['revenue'] = pd.to_numeric(movies['revenue'], errors='coerce')
movies['runtime'] = pd.to_numeric(movies['runtime'], errors='coerce')

# id가 없는 영화 제거
movies = movies.dropna(subset=['id']).copy()
# id를 정수형으로 변환
movies['id'] = movies['id'].astype(int)
# 동일한 TMDb id는 중복방지를 위해 첫 번째 값만 사용
movies = movies.drop_duplicates(subset=['id'], keep='first').copy()
```

전처리 ② 유효 데이터 선별 · ID 연결 수정

잘못된 영화 연결을 막고 분석 가능한 표본을 확보

핵심 처리

① budget > 1,000 & revenue > 1,000 필터

② ratings.movieId

→ links.tmbld

→ movies.id

(movies의 id와 ratings의 movieId는 같은 ID 체계가 아니기 때문)

```
# 예산 또는 매출이 지나치게 작게 기록된 데이터 제외
df = movies[
    (movies['budget'] > 1000) &
    (movies['revenue'] > 1000)
].copy()

# ratings_small의 movieId는 MovieLens ID
# movies_metadata의 id는 TMDB ID
# link.csv를 이용해 movieId → tmbdId → movies_metadata.id

links_clean = links[['movieId', 'tmbdId']].copy()
# tmbdId를 숫자형으로 변환
links_clean['tmbdId'] = pd.to_numeric(
    links_clean['tmbdId'],
    errors='coerce')
# ratings_small에 TMDB ID 연결
ratings_linked = pd.merge(
    ratings,
    links_clean,
    on='movieId',
    how='inner')
# TMDB ID가 없는 행 제거
ratings_linked = ratings_linked.dropna(subset=['tmbdId']).copy()
ratings_linked['tmbdId'] = ratings_linked['tmbdId'].astype(int)
```

수정 후 최종 모델링 표본: 5,306편

전처리 ③ 파생변수 생성

원본 정보를 모델이 활용하기 쉬운 형태로 재구성

변수 생성

개봉 계절, 장르를 모델의 입력 변수로 만들기

- release_date → month → season
Spring / Summer / Autumn / Winter
- genres → main_genre
영화 1개를 설명하는 여러 장르 중 처음 1개를
메인 장르로 설정

```
# 개봉일을 이용해 계절 변수 생성
df['release_date'] = pd.to_datetime(
    df['release_date'],
    errors='coerce')
df['month'] = df['release_date'].dt.month

def get_season(month):
    if month in [3, 4, 5]:
        return 'Spring'
    elif month in [6, 7, 8]:
        return 'Summer'
    elif month in [9, 10, 11]:
        return 'Autumn'
    elif month in [12, 1, 2]:
        return 'Winter'
    else:
        return np.nan

df['season'] = df['month'].apply(get_season)

# 영화의 대표 장르 추출
def parse_first_genre(genre_str):
    try:
        genres = ast.literal_eval(genre_str)

        if len(genres) > 0:
            return genres[0]['name']
    except:
        pass
    return 'Other'

df['main_genre'] = df['genres'].apply(parse_first_genre)
```

전처리 ④ 로그 변환 · 모델 입력 준비

값의 격차를 줄이고 범주형 변수를 머신러닝에 맞게 변환

마지막 정리

① budget, revenue에 로그 변환

→ 영화별 예산과 매출의 규모 차이가 매우 크므로 값의 편차를 완화하기 위함

② 장르·계절은 One-Hot Encoding

→ 문자 범주를 모델이 계산 가능한 형태로 변환

③ runtime 또는 season 결측 영화 제거

```
# 예산과 매출 로그 변환
df['log_budget'] = np.log(df['budget'])
df['log_revenue'] = np.log(df['revenue'])


# 머신러닝용 입력 변수 생성
# 범주형 변수인 season과 main_genre는 One-Hot Encoding을 적용

X = pd.get_dummies(
    df[
        [
            'log_budget',
            'runtime',
            'season',
            'main_genre'
        ]
    ],
    drop_first=True,
    dtype=float
)

# 회귀분석 등에 사용할 수 있도록 상수항 추가
X = sm.add_constant(X)
# 결측치 제거(runtime이나 season이 없는 경우)
df = df.dropna(
    subset=['runtime', 'season']
).copy()
```

EDA ① 제작비와 매출

숫자형 변수끼리의 선형 관계를 산점도와 상관계수로 확인



- 점 하나 = 영화 한 편
- 제작비와 매출의 상관 관계

결과


상관계수 ≈ 0.646

→ 비교적 뚜렷한 양(+)의 관계

제작비가 높은 영화일수록 매출도 높은 경향.
단, 제작비가 흥행의 원인이라는 뜻은 아님.

EDA ② 러닝타임과 매출

영화 길이와 매출 사이에 뚜렷한 관계가 있는지 확인



- x축 = 러닝타임(분)
- y축 = 로그 매출
- 점이 특정 방향으로 뚜렷하게 모이는지 확인

결과


상관계수 ≈ 0.198

→ 약한 양(+)의 관계

긴 영화가 매출이 조금 높은 경향은 있으나,
러닝타임만으로 매출을 설명하기는 어렵다.

EDA ③ 장르별 매출 수준

범주형 변수이므로 상관계수 대신 장르별 로그 매출 중앙값 비교



- 높이↑→해당 장르의 전형적인 매출 수준↑
(평균 대신 중앙값을 사용해 초대형 흥행작의 영향을 완화함.)


결과

상위 8개 장르 중 Animation · Adventure의 중앙값이 상대적으로 높게 나타남

장르별 매출 수준 차이는 보이지만, 장르가 흥행을 직접적으로 일으킨다고 단정할 수는 없다.

EDA ④ 개봉 계절별 매출 수준

계절별 로그 매출 중앙값을 비교해 개봉 시기의 차이를 확인



- 각각의 Season별 막대 높이를 비교
- 높이↑→ 개봉작의 중앙 매출↑

결과

- Max: Summer
- Min: Autumn이 가장 낮음.
- (다만, 차이는 제작비 요인보다 작음)

각각의 계절을 “개별 관계”를 보는 단계.

다음 모델링에서는 동시에 고려해 종합적인 예측력을 본다

모델링 ① Random Forest 회귀 — 정확한 매출 예측

네 가지 개봉 전 정보만으로 실제 매출 규모를 얼마나 설명할 수 있는지 확인

입력 X

- 장르
- 러닝타임
- 로그 제작비
- 개봉 계절

학습 방식

- Train 80%
- Test 20%
- Random Forest
- 300 trees

목표 y

- 로그 매출
(log_revenue)
- 연속값 예측


평가 지표

- MAE
- RMSE
- R^2

회귀의 역할: “네 변수만으로 정확한 매출액을 맞힐 수 있는가?”를 시험하는 첫 번째 모델.

회귀 결과 해석

R^2 와 실제값-예측값 산점도로 모델의 한계를 확인



핵심 지표

MAE = 1.177

RMSE = 1.629

$R^2 = 0.386$

해석 방법

대각선 = 실제값과 예측값이 완전히 같은 경우
점이 대각선에서 멀수록 예측 오차가 큼

네 변수만으로 정확한 매출 규모 예측의 어려움
→ “흥행작 여부 분류”에 대한 추가 분석

모델링 ② Random Forest 분류 — 흥행작 여부 예측

정확한 금액 대신 “상위 25% 고매출 영화인지”를 맞추는 문제로 단순화

흥행작 정의

매출 75% 분위수 $\approx$ \$100.6M

상위 25% $\rightarrow$ 1

나머지 75% $\rightarrow$ 0

입력 변수

장르 · 러닝타임

로그 제작비 · 계절

회귀와 동일한 4개 변수

학습 설정

Train/Test 8:2

stratify 적용

class_weight=balanced

평가

Accuracy

Precision

Recall

F1 · ROC-AUC


분류 분석으로 방향을 바꾼 이유

- 정확한 매출 금액은 다양한 외부 요인 때문에 오차가 큼
- 대신 “흥행권에 진입할 가능성”을 구분하는 것이 더 현실적인 질문

분류 분석의 방향 : 개봉 전 정보만으로 흥행작과 일반 영화를 구분할 수 있는지 여부 확인

분류 결과 해석

혼동행렬과 ROC-AUC로 흥행작 구분 성능을 평가



성능 지표

- Accuracy 0.801 · Precision 0.591
- Recall 0.669 · F1 0.628
- ROC-AUC 0.830


결과 해석

- 실제 고매출 266편 중 178편을 고매출로 맞춤
- 88편은 일반 영화로 놓침

정확한 매출 예측은 어려웠지만, 고매출 영화와 일반 영화를 구분하는 능력은 일정 수준 확인됨.

모델링 ③ Permutation Importance

분류 모델이 어떤 정보를 가장 많이 의존했는지 확인



변수 하나를 무작위로 섞어 정보력을 깨뜨린 뒤
ROC-AUC가 얼마나 떨어지는지 측정
→ 크게 떨어질수록 중요한 변수

결과

- 제작비 ≈ 0.290
- 러닝타임 ≈ 0.009
- 장르 ≈ 0.006
- 계절 ≈ 0.004

네 가지 개봉 전 정보 중 “제작비”가 고매출 영화 예측에서 압도적인 중요한 정보임.

결론

① 매출과의 기초 관계

- 제작비: 비교적 강한 양의 관계
- 러닝타임: 약한 관계
- 장르·계절: 그룹별 차이 존재

② 예측 가능성

- 정확한 매출 예측 $R^2 \approx 0.386$
→ 금액 예측에는 한계
- 흥행작 분류 ROC-AUC ≈ 0.830
→ 구분 가능성은 확인

③ 핵심 요인

- Permutation Importance 결과
- 제작비가 가장 중요한 예측 정보
- 단, “제작비가 흥행을 원인적으로 만든다”는 결론은 아님
- -> 사전에 알 수 있는 자료 중, 흥행 예측에 유용한 정보라는 뜻

개봉 전 기본 정보만으로 정확한 매출을 맞추기는 어렵지만, 흥행권 진입 여부를 구분하는 데에는 일정한 예측력이 있으며 그중 제작비의 정보력이 가장 큼

한계점과 다음 분석 방향

데이터 한계

- 예산·매출 1,000달러 이하 제거 기준은 실무적 필터이며 통계적 이상치 기준은 아님
- 장르는 첫 번째 장르만 대표값으로 사용
- MovieLens 평점은 참고 정보이며 모델 입력에는 미사용

모델 한계

- 마케팅비, 배급 규모, 배우·감독 인지도 등 중요한 요인이 빠져 있음
- 상위 25%를 ‘흥행작’으로 정의한 것은 분석 목적의 기준
- Random Forest 결과는 예측 관계이지 인과관계가 아님

확장 방향

- credits.csv → 배우·감독 변수 추가
- keywords.csv → 키워드/소재 정보 활용
- 연도·국가·배급사 등 변수 확장
- 다른 모델과 성능 비교