Kuggle
14th 손재강

Kuggle 6주차

차원 축소

Table of Contents

목차

01. 차원 축소의 **정의**와 고차원 데이터의 한계

02. **차원의 저주**가 가진 문제점

03. 특징 선택 (Filter vs Wrapper)

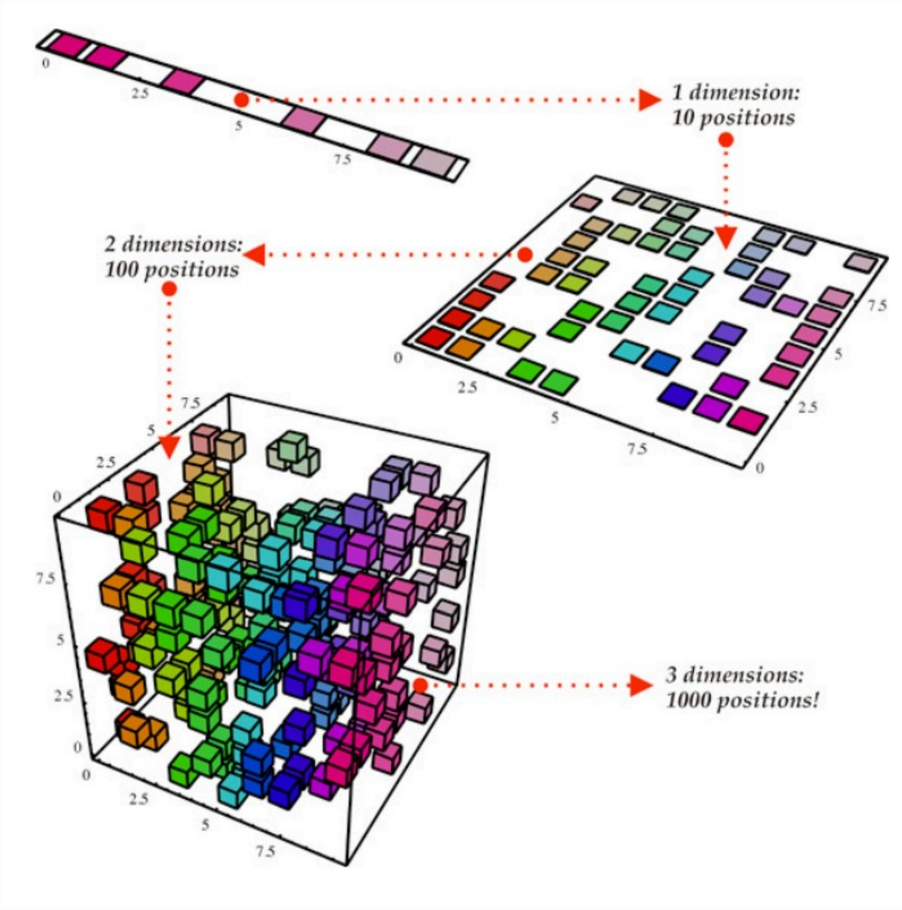
04. 특징 추출의 핵심, **PCA (주성분 분석)**

05. 차원 축소의 **시각화**

차원 축소란?

데이터를 고차원에서 저차원으로 변환시키는 기법

단순히 데이터를 버리는 것이 아니라, 변환 과정을 통해 데이터가 가진 의미 있는 특성을 최대한 보존하는 것이 핵심 목적입니다.



고차원 데이터의 한계

①

비효율성

차원이 많을수록 모델 훈련과
예측에 걸리는 계산 시간이
기하급수적으로 길어짐

②

데이터 희소성

고차원 공간에서는 데이터 포인트
사이의 거리가 서로 멀어지고
텅 빈 공간이 많아짐

③

과적합

모델이 불필요한 노이즈까지
정답으로 오해하여, 훈련 데이터에는
완벽하지만 실제 테스트 데이터에서
예측력이 뚝 떨어짐

특징 선택

필요한 변수만 쏙 골라내는 방법

이때, 선택의 기준은 방법에 따라 다름

필터 방식 (Filter)

통계적 지표를 활용해 모델 학습 전에 분산이 낮거나 상관관계가 떨어지는 변수를 걸러내는 방식

래퍼 방식 (Wrapper)

전진 선택이나 후진 단계적 선택처럼 모델을 반복 학습시키며 최적의 조합을 찾는 방식

특징 추출

데이터의 중요한 특징만을 고려하여 완전히
다른 새로운 변수로 재구성하는 방법

PCA
MDS
LDA

선형 데이터 대상 기법

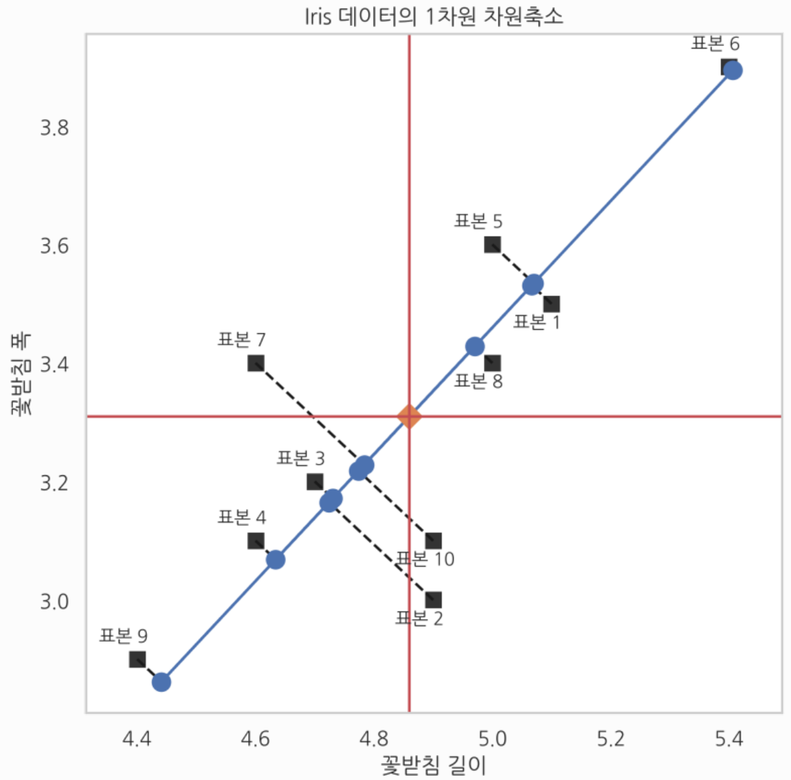
t-SNE

비선형 데이터 대상 기법

PCA 주성분 분석

선형 데이터를 대상으로 하는 대표적인 비지도 학습 방식

데이터의 분산이 최대로 보존되는 축을 선택하는 것이 정보가 가장 적게 손실되므로 합리적임



다양한 PCA 기법들

기본 PCA	중소 규모 데이터에 적합하며 높은 정확도를 보이지만, 메모리 용량의 제약이 있음
점진적 PCA	초대형 데이터를 쪼개서 배치 처리하므로 메모리를 절약할 수 있지만 학습 속도는 다소 느림
랜덤 PCA **랜덤 투영**	랜덤 PCA는 대형 데이터에서 극강의 처리 속도가 필요할 때 근사치를 기반으로 속도를 높임 랜덤 투영은 데이터 해석은 불가능해지지만 거리를 보존하며 처리 속도를 극한으로 끌어올림

MDS와 LDA

MDS

추천 시스템 등에서 희소 행렬을 다루거나 고차원의
관계 정보를 저차원 좌표로 변환할 때
→ 개체 간의 **실제 거리**를 보존하는 차원 축소 방식

↔

LDA

차원 축소의 목적이 분류 (Classification) 성능 향상
→ 정답지 정보를 활용하는 지도 학습 방식

t-SNE

샘플 간 거리를 보존하면서 좌표 공간의 차원을 낮춤

→ 고차원의 관계를 저차원 좌표로 변환하는 기법

가까운 이웃 간의 확률적 유사도를 핵심 보존 대상으로 여김

- 주로 **시각화**에 아주 많이 사용되며, 특히 수많은 변수를 가진 고차원 샘플들이 어떤 군집을 이루고 있는지 2차원 평면상에 시각화하여 파악할 때 유용함

- 데이터가 2차원 공간에 좌표로 찍히기는 하지만 결과로 나온 x축과 y축은 아무런 **물리적 의미가 없다**는 점에 유의해야 함

