



회귀분석

(Regression Analysis)

KUGGLE 14기 권진서

목차 Contents

I. 회귀분석이란?

II. 회귀분석 종류

III. 선형회귀분석 원리

IV. 선형회귀의 가정


V. 회귀 모델 평가

VI. 과대적합 & 과소적합 문제

VII. 파이썬으로 회귀분석하기

I. 회귀분석이란?


- “모든 것은 평균으로 회귀(돌아간다)한다.”
- 독립변수와 종속변수 사이의 관계를 수학적 모형으로 나타내어 독립변수에 해당하는 자료로부터 이 모형을 추정해 예측하는 통계적 분석방법.



➤ Ex) 가계소득(독립변수 X)으로부터 저축액(종속변수 Y) 예측
→ 변수 간의 관계 파악 및 저축액 예측


II. 회귀분석 종류

- 선형 회귀 – 파라미터가 선형 결합된 형태, 독립변수의 개수/차수에 따라 분류




- 단순선형회귀식
(독립변수가 1개일 때)

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$



- 다중선형회귀식
(독립변수가 2개 이상일 때)

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \epsilon_i$$




- 다항회귀식
(독립변수의 n차 항을 포함)

$$Y_i = \beta_0 + \beta_1 X + \beta_2 X^2 + \epsilon_i$$

II. 회귀분석 종류

- 비선형 회귀 – 파라미터가 지수, 분모 등 비선형으로 결합




➤ 로지스틱 회귀 모델

: 결과 변수가 0/1(Yes/No)같은 범주형으로 분류될 때

$$g(x) = \frac{e^x}{1 + e^x}$$

III. 선형회귀분석 원리

- 데이터들의 특징을 가장 잘 설명할 수 있는 하나의 직선으로 요약하는 방법
 - 그 직선은 여러 개가 될 수 있다.
 - 계산적 방법: 최소제곱법 (Ordinary Least Squares, OLS)



“잔차들의 제곱을 최소화”


$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

IV. 선형회귀의 가정


선형성

- 독립변수와 종속변수 사이에 선형적인 관계가 있어야 함.
- [산점도 예]



독립성


- 각 데이터의 잔차들은 서로 영향을 주지 않고 독립적이어야 함.
- [잔차 산점도 예]



IV. 선형회귀의 가정


정규성

- 잔차들이 정규분포를 이뤄야 함.
- [Q-Q 플롯 예]



등분산성

- 예측값의 크기와 상관없이 잔차의 분산이 일정해야 함.
- [잔차 산점도 예]



V. 회귀 모델 평가

■ 회귀 모델을 평가하는 두 가지 관점

상대적 평가

Y 의 평균 모델의 오차

vs

회귀 모델의 오차

R-Squared

(결정계수)

Adjusted
R-Squared

(수정된 결정계수)

모델의 설명력

- 오차의 비
- 1에 가까울수록 좋음

절대적 평가

실제 값 Y

vs

예측 값 $\hat{Y}$

MSE

RMSE

MAE

잔차 그 자체의 크기

- 오차의 양

V. 회귀 모델 평가

- MSE (Mean Squared Error, 평균 제곱 오차)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- RMSE (Root Mean Squared Error, 평균 제곱근 오차)

$$\text{RMSE} = \sqrt{\text{MSE}}$$

- MAE (Mean Absolute Error, 평균 절대 오차)


$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- R-squared (결정계수)

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} = 1 - \frac{\text{SSE}}{\text{SST}} = \frac{\text{SSR}}{\text{SST}}$$

VI. 과대적합 & 과소적합 문제

- 편향과 분산(Bias-Variance Tradeoff)
 - 편향(Bias): 예측값과 실제값 간의 차이 (정확도)
 - 분산(Variance): 동일한 모델에 다른 데이터셋 사용 시 예측값의 변동 정도



VI. 과대적합 & 과소적합 문제

- 훈련 세트와 데이터 세트

- 훈련 세트를 활용하여 모델 훈련 후, 훈련 세트와 테스트 세트에서 평가
- 훈련 세트와 테스트 세트를 보통 7:3, 8:2로 분류



- 훈련 세트로 훈련했기 때문에 훈련 세트의 점수가 더 높게 나오는 경향이 있음
(R-Squared: 결정계수 값, 1에 가까울수록 설명을 잘 하는 모델)
- 훈련 세트 점수가 테스트 세트 점수보다 훨씬 높으면 → 과대적합
- 테스트 세트 점수가 훈련 세트 점수보다 높거나, 두 점수 모두 낮으면 → 과소적합

VI. 과대적합 & 과소적합 문제

- 과대적합(Overfitting)


- 정의: 모델이 학습 데이터에 과하게 맞춰져 실전 예측력이 떨어지는 상태 (노이즈까지 학습)

- 특징

- 1) 훈련 세트에 대한 성능 >> 테스트 세트에 대한 성능

- 2) 설명 변수가 너무 많음


- 3) 복잡한 모델에서 자주 발생 (ex. 너무 많은 변수, 너무 깊은 신경망 등)



VI. 과대적합 & 과소적합 문제

■ 과대적합(Overfitting) 해결 방법

- 1) 모델 복잡도 감소 → 모델 단순화
- 2) 더 많은 데이터 사용
- 3) Early Stopping 적용 → 과대적합 전에 학습 중단
- 4) 정규화 적용 → L1, L2 정규화 활용



VI. 과대적합 & 과소적합 문제

- 과소적합(Underfitting)

- 정의: 모델이 너무 단순하여 데이터에 내재된 기본적인 규칙이나 패턴조차 학습하지 못한 상태


- 특징

- 1) 훈련 세트에 대한 성능 << 테스트 세트에 대한 성능

- 2) 훈련 세트에 대한 성능 ↓ 테스트 세트에 대한 성능 ↓


- 3) 너무 단순한 모델에서 자주 발생

- (ex. 선형 회귀로 비선형 관계를 학습하려는 경우)



VI. 과대적합 & 과소적합 문제

- 과소적합(Underfitting) 해결 방법
 - 1) 모델 복잡도 증가 → 더 복잡한 모델 사용
 - 2) 더 많은 Feature 추가 → 유의미한 변수 추가



VII.파이썬으로 회귀분석하기

- scikit-learn 라이브러리의 LinearRegression을 이용한 단순 선형 회귀 코드

필요한 라이브러리 불러오기

```
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
```

데이터 준비

```
X_simple = X
y_simple = y
```

VII.파이썬으로 회귀분석하기

데이터를 train/test로 분할 (test_size는 임의로 0.3으로 설정)

```
X_train, X_test, y_train, y_test = train_test_split  
                                (X_simple, y_simple, test_size=0.3, random_state=0)
```

LinearRegression 모델 학습

```
lin_reg_s = LinearRegression().fit(X_train, y_train)
```

회귀 모델 평가

```
print("-단순 회귀-")  
print("Train R2 :", lin_reg_s.score(X_train, y_train))  
print("Test R2 :", lin_reg_s.score(X_test, y_test))
```

-단순 회귀-

Train R² : 0.5436831727782818

Test R² : 0.5111935275378604

감사합니다.

Thank you for your attention.

KUGGLE 14기 권진서