

사전훈련 및 미세조정 & 강화학습

(Pre-Training & Fine-Tuning & Reinforcement Learning)

KUGGLE 14기 권진서 장재원

목차 Contents

- I. 트랜스포머 이후의 질문
- II. 파운데이션 모델
- III. 사전학습
- IV. 미세조정
- V. SFT의 한계
- VI. 강화학습 (Reinforcement Learning)
- VII. RLHF
(Reinforcement Learning from Human Feedback)
- VIII. DPO (Direct Preference Optimization)
- IX. RLHF vs DPO 비교
- X. 결론

I. 트랜스포머 이후의 질문

◆ 문장 속 관계를 파악하기

“개가 사람을 물었다”

“사람이 개를 물었다”

- 어텐션은 문맥 속 토큰 간 관계를 반영한다.

◆ 사용자의 요청에 맞게 답하기

“두 문장의 차이를 설명해줘”

- 지시를 따르는 응답은 학습 목표와 데이터의 영향을 받는다.

➤ 모델 구조에 더해, 무엇을 어떻게 학습시키느냐가 중요하다

II. 파운데이션 모델

- ◆ 광범위한 데이터로 학습해 여러 하위 작업에 적용할 수 있는 기반 모델

작업별로 따로 학습	하나의 기반 모델을 여러 작업에 적용
감성 분석 데이터 → 감성 분석 모델	광범위한 데이터 → 파운데이션 모델
번역 데이터 → 번역 모델	기반 모델을 요약/분류/번역 등에 활용
작업마다 학습을 반복	공통 능력을 재사용하고 목적에 맞게 조정

- Foundation = 다양한 응용의 출발점

III. 사전학습

◆ 방대한 텍스트로 학습

- 언어의 규칙과 다양한 패턴을 익혀 여러 작업에 활용할 기반을 만든다.

◆ 다음 토큰 예측

- 텍스트 안에 입력과 정답이 함께 있다.

앞부분: 입력	이어지는 부분: 예측할 대상
“프랑스의 수도는”	“파리”
“프랑스의 수도는 파리”	“이다”

- 정답을 사람이 하나씩 붙이지 않아도 학습 신호를 얻을 수 있음
→ 반복적인 예측을 통해 문법/문맥/사실적 연관성을 학습한다.

III. 사전학습

◆ 사전학습을 좌우하는 데이터와 자원

◆ 데이터

- 양뿐 아니라 품질과 다양성
→ 웹 문서의 중복 / 스팸 / 노이즈를 줄이고 다양한 분야와 문체의 텍스트를 확보한다.

Ex) Common Crawl: 웹 수집 자료 / The Pile: 다양한 출처의 텍스트 모음

◆ 연산 자원

- 모델 규모 / 학습 토큰 수 / 학습 시간
→ 대규모 사전학습에는 많은 계산과 비용이 필요하다.

IV. 미세조정

- ◆ 목적에 맞는 데이터로 추가 학습
 - 기존 모델의 가중치를 조정해 특정 작업이나 응답 방식에 적용시킨다.
- ◆ 정렬: 모델의 행동을 인간의 의도에 맞는 응답으로 만드는 과정
- ◆ 정렬의 목표: 모델의 행동을 인간의 의도와 가치에 맞추기
 - 미세조정은 모델을 특정 목적에 맞게 조정하는 학습 과정이다.
- ◆ Ex) 사용자: “광합성을 한 문장으로 설명해줘.”

텍스트를 이어 쓰는 응답	요청에 맞는 응답
“호흡도 한 문장으로 설명해줘. 증산 작용도 설명해줘.”	“광합성은 식물이 빛 에너지로 이산화탄소와 물에서 당을 만드는 과정이다.”

IV. 미세조정

◆ SFT (Supervised Fine-Tuning)

- 정답 레이블이 있는 데이터로 지도학습
- 사전학습된 모델을 정답 응답이 있는 데이터로 추가 학습한다.

◆ 정렬의 목표: 모델의 행동을 인간의 의도와 가치에 맞추기

- 미세조정은 모델을 특정 목적에 맞게 조정하는 학습 과정이다.

◆ 질문에는 답변을, 요약 요청에는 요약을, 분류 요청에는 분류를

- 지식 주입만을 목표로 하기 보다, 지시 이행과 응답 방식을 조정하는 데 초점

• Ex) 지시

“다음 문장을 긍정 또는 부정으로 분류해줘.”
문장: “배송이 빠르고 제품도 마음에 들어요.”

모범 응답

“긍정”

IV. 미세조정

◆ 사전학습 & 미세조정(SFT) 두 개념의 핵심 정리

구분	사전학습	SFT
학습 데이터	광범위한 텍스트	지시와 바람직한 응답
주요 역할	범용적인 언어 능력의 기반	지시 이행과 응답 방식 조정
관계	먼저 기반을 학습	기반 모델을 추가로 학습

- 사전학습으로 기반을 만들고, SFT로 지시에 맞는 응답을 학습한다.
- 사전학습 모델 → 미세조정 → 목적에 맞게 조정된 모델

V. SFT의 한계

◆ 지식 향상의 실패

- 사전학습에 없던 낯선 지식을 강제로 주입하면 기존 지식 기반과 충돌하여 오히려 성능 저하

◆ 파국적 망각 및 지식 저하

- 특정 분야 전문가로 튜닝하려다 모델이 가진 기본적인 상식을 완전히 잃어버림

◆ 환각 증가

- 모델이 모르는 질문에 응답해야 할 때, 데이터셋 내에서 유사한 스타일을 차용해 사실이 아닌 내용을 그럴듯하게 꾸며낼 수 있음



◆ 맹목적 패턴 모방

- 단답형 질문에도 데이터셋에 내재된 정답지의 표면적인 장황한 스타일까지도 불필요하게 복사함

Ex) 〈질문〉 “프랑스의 수도는 파리인가요?”	〈이상적인 답변〉 “네. 파리가 맞습니다.”	〈SFT의 한계가 드러난 답변〉 “안녕하세요! 질문해 주신 내용에 대해 기쁜 마음으로 답변해 드리겠습니다. 네, 맞습니다. 프랑스의 수도는 파리(Paris)입니다. 파리는 프랑스 중북부 센강 연안에 위치해 있으며 ... (중략) ... 이 답변이 프랑스에 대한 궁금증을 해소하는 데 도움이 되셨기를 바라며 ... (생략)”
---	--	--

VI. 강화학습 (Reinforcement Learning)

- ◆ SFT는 단 하나의 정답을 맹목적으로 모방할 뿐, 인간의 복잡하고 주관적인 가치와 의도를 맞추지 못함 → 강화학습의 등장
- ◆ 강화학습 (RL)
 - 명확한 정답이 없는 상황에서 보상이라는 피드백 신호를 통해 최적의 행동 전략을 탐색하고 학습하는 방법
 - SFT의 한계 극복, 인간의 가치에 부합하는 AI를 만들기 위한 전환



VI. 강화학습 (Reinforcement Learning)

- ◆ '에이전트'가 '환경'과 상호작용하며 '보상'을 최대화하는 '정책'을 학습하는 과정



	강화학습	Ex. 강아지 훈련
에이전트(Agent)	학습 주체 (LLM)	훈련받는 강아지
상태(State)	사용자의 프롬프트 (Prompt)	주인의 명령어 (Ex. "앉아!")
행동(Action)	토큰 예측 및 텍스트 생성	강아지의 실제 동작
보상(Reward)	인간 선호도 기반 수치적 점수	간식과 칭찬 (높은 보상 점수) or "아니야" (낮은 보상 점수)

- ◆ 정답을 모방하는 것이 아닌, 보상을 최대화하기 위한 시행착오를 통해 최적의 행동 전략을 발견하는 과정

VI. 강화학습 (Reinforcement Learning)

◆ 정책 (Policy, π)

- 강화학습에서 에이전트가 행동을 결정하는 규칙 또는 전략
- LLM 맥락에서 정책은 모델 파라미터 그 자체
- 상태(프롬프트/대화) → 정책(모델 파라미터) → 다음 토큰 확률분포 → 행동(토큰 생성)

◆ 강화학습의 목표

- 누적 보상의 기댓값 최대화
- 유용하고, 진실하며, 무해한 응답 지향

VII. RLHF (Reinforcement Learning from Human Feedback)

◆ 인간 피드백 기반 강화학습 (RLHF)

- 인간이 직접 제공한 선호도 데이터를 강화학습의 보상으로 활용하여 모델을 정렬하는 기법


Step 1. SFT (Supervised Fine-Tuning)

- SFT 모델은 강화학습 단계의 초기 정책 역할
- SFT 모델의 행동 방향을 인간의 선호도라는 더 미묘한 목표에 맞춰 미세조정



Step 2. 보상 모델 (Reward Model, RM) 훈련

- 보상 모델: 인간의 선호도를 학습하여 이를 대신 평가해 줄 모델



- 선택된 응답의 보상 점수는 최대화, 거부된 응답의 보상 점수는 최소화

VII. RLHF (Reinforcement Learning from Human Feedback)

Step 3. 정책 최적화 (RL Fine-Tuning with PPO, Proximal Policy Optimization)

- 목적 함수

$$\mathcal{L}(\theta) = \mathbb{E}_{(x,y) \sim \pi_{\theta}} \left[R_M(x, y) - \beta D_{\text{KL}}(\pi_{\theta}(\cdot|x) \parallel \pi_{\text{ref}}(\cdot|x)) \right]$$


- 1) 보상 극대화: 모델이 보상 모델로부터 높은 점수를 받는 응답을 많이 생성하도록 유도
- 2) KL 발산 페널티: 보상 해킹과 파국적 망각을 막기 위한 제약 장치

➤ 보상은 크게, KL 발산은 작게 하여 목표함수 $\mathcal{L}(\theta)$ 를 극대화하는것이 목표

VII. RLHF (Reinforcement Learning from Human Feedback)

◆ RLHF의 한계

- 다단계 프로세스이기 때문에 훈련이 발산하기 쉽고, 디버깅이 극도로 어려움
 - 다양한 모델을 사용하여 상당한 계산 자원을 요구하기에 계산 비용이 매우 높음
- 이러한 복잡성과 비용은 RLHF를 소수의 거대 연구 기관만이 접근할 수 있는 기술로 만들었고, 이에 따라 더 많은 연구자와 개발자들을 위한 경량화된 대안의 필요성 증대



VIII. DPO (Direct Preference Optimization)

◆ DPO의 핵심

- 명시적인 보상 모델을 훈련하고 강화학습을 수행하는 복잡한 과정을 건너뛸 수 있다.
- 보상 함수와 최적 정책 사이의 특정한 수학적 관계를 보상 함수로 표현
→ 정책 모델을 직접 최적화

◆ DPO 손실 함수

- 복잡한 RLHF 파이프라인을 인간 선호도 데이터에 대해 간단한 이진(Binary) 분류 문제로 치환
- 학습 목표: 프롬프트/인간이 선호한 응답/거부한 응답이 주어졌을 때,
정책 모델이 인간의 선호 응답을 생성할 확률은 높이고, 거부한 응답은 생성할 확률은 낮추도록 훈련

$$L_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim D} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

x : 입력 프롬프트

π_{ref} : 기준(참조) 모델

y_w : 선호된 응답(preferred answer)

β : KL 제약 강도를 조절하는 하이퍼파라미터

y_l : 덜 선호된 응답(less preferred answer)

σ : 시그모이드 함수

π_{θ} : 현재 학습 중인 정책 모델

IX. RLHF vs DPO 비교

	RLHF (Reinforcement Learning from Human Feedback)	DPO (Direct Preference Optimization)
핵심 원리	보상 모델 학습 후 강화학습으로 정책 모델 튜닝	선호도 데이터로 직접 정책 모델 튜닝
필요한 모델 수	4개 (무거움/메모리↑)	2개 (가벼움/메모리↓)
훈련 단계	3단계 (SFT → RM → PPO)	2단계 (SFT → DPO)
복잡도 및 안정성	매우 복잡하고 디버깅 어려움	단순한 지도학습 파이프라인, 디버깅 용이함
데이터 효율성	덜 효율적, 많은 샘플링 필요	더 효율적, 샘플링 필요 없음

X. 결론

◆ 학습 패러다임의 진화 요약

- 1세대 – 지식의 압축 (Pre-training): 사실일 가능성이 높은 것 생성
 - 2세대 – 행동의 모방 (SFT): 인간이 옳다고 한 것 생성
 - 3세대 – 선호의 내재화 (RLHF/DPO): 인간이 더 선호하는 것 생성
-
- 통계적 패턴 학습에서 시작된 AI는 이제 내재화된 가치 판단의 영역으로 나아가고 있음.
 - 차세대 모델들은 멀티모달 이해, 추론 능력, 더욱 정교한 정렬 기법을 통해 인간과의 협업 능력을 한층 더 높일 것

감사합니다

THANK YOU FOR YOUR ATTENTION

KUGGLE 14기 권진서 장재원