KUGGLE 7주차

군집화

14기 박세준

WEEK 07

CONTENTS

CHAPTER 01

군집화란?

군집화의 기본 개념

CHAPTER 02

전처리

거리측정과 데이터 조정

CHAPTER 03

K-means

작동 원리와 한계

CHAPTER 04

계층 군집

덴드로그램과 연결 방법

CHAPTER 05

DBSCAN

밀도로 찾는 군집

CHAPTER 06

군집 평가

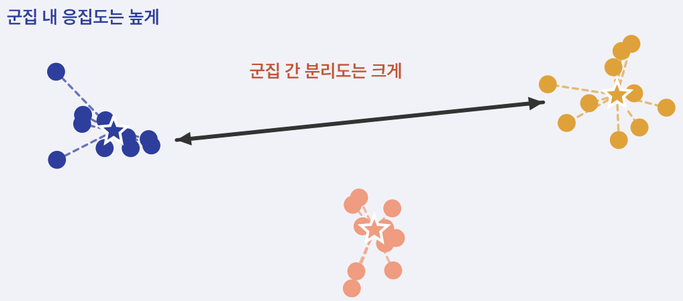
실루엣, 엘보우

비지도 학습과 군집화

분류와 군집화

	분류	군집화
학습 방식	지도 학습	비지도 학습
데이터	정답 레이블 있음	정답 레이블 없음
목표	레이블 예측 (Predict)	숨은 그룹 발견 (Discover)

군집화의 두 원칙



POINT 1

비지도 학습이란

정답(레이블)이 없는 데이터로 학습하는 방식임.

레이블을 예측하는 분류(지도 학습)와 달리,

군집화는 데이터 안에 숨어 있는 그룹을 발견하는 것이 목적임.

POINT 2

군집화의 정의와 원칙

군집분석은 여러 변수로 관측한 n개의 개체를 비슷한 것끼리 묶는 다변량 분석 기법임. 군집 내 응집도는 높이고 군집 간 분리도는 크게 만드는 것이 두 원칙임.

군집화의 활용 사례

CASE 1



고객 분류

구매 패턴이 비슷한 고객을 묶어
그룹별로 다른 마케팅을 적용함.

CASE 2



콘텐츠 추천

취향이 비슷한 사용자를 묶고,
같은 그룹이 본 콘텐츠를 추천함.

CASE 3



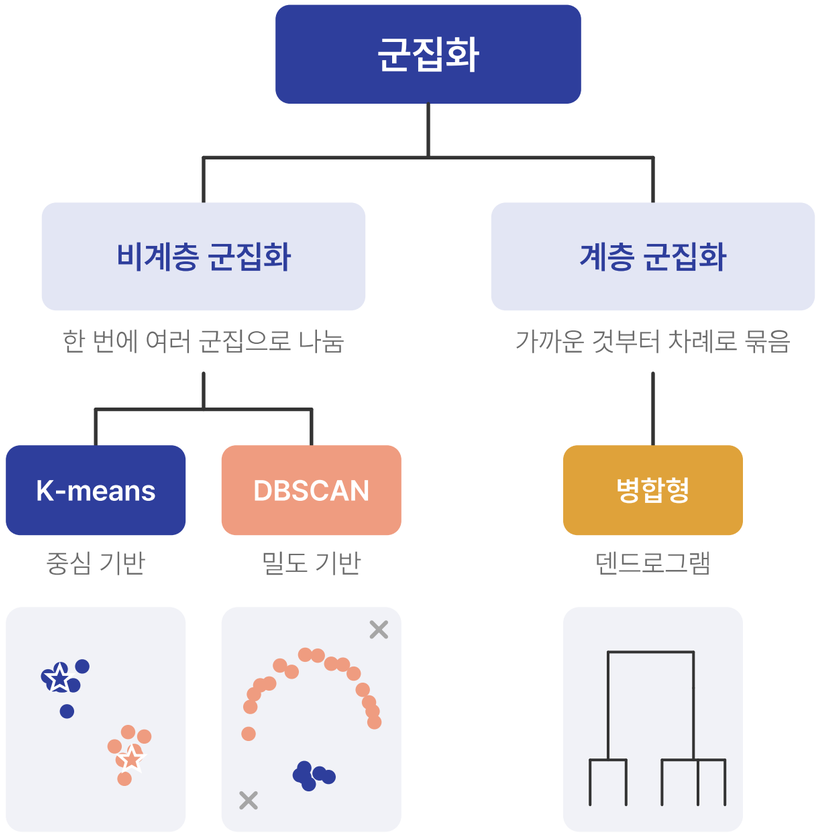
이상치 탐지

어느 군집에도 속하지 않는
데이터로 이상 거래를 찾음.

지도 학습 전에 데이터 구조를 이해하는 데에도 유용함

유사 이미지 검색, 차원 축소, 적은 레이블을 늘리는 준지도 학습에도 활용됨.

군집화 알고리즘 종류



POINT 1

비계층 군집화

데이터를 한 번에 여러 군집으로 나누는 방식임.

중심 기반의 K-means와 밀도 기반의 DBSCAN이 대표적임.

POINT 2

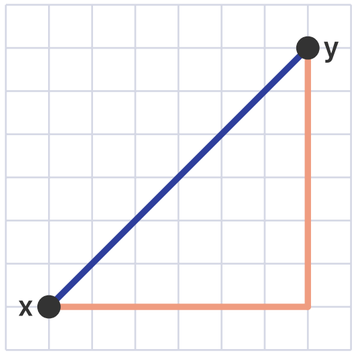
계층 군집화

가장 가까운 개체끼리 하나씩 묶어 나가는 방식임.

묶인 과정을 덴드로그램으로 그릴 수 있어서 군집 수를 나중에 정할 수 있음.

거리 측정

두 점 사이 거리



수학적 거리

유클리드

$$d = \sqrt{\sum_i (x_i - y_i)^2}$$

맨해튼

$$d = \sum_i |x_i - y_i|$$

민코프스키 p = 1 맨해튼, p = 2 유클리드

$$d = \left(\sum_i |x_i - y_i|^p\right)^{1/p}$$

통계적 거리

표준화 거리

변수마다 표준편차로
나눈 뒤 유클리드 거리

마할라노비스 거리

$$d = \sqrt{(x - y)^T S^{-1} (x - y)}$$

S는 공분산 행렬, 변수 사이 상관까지 반영

유사도

코사인 유사도

$$\cos\theta = x \cdot y \,/\, (\|x\| \|y\|)$$

−1 ~ 1, 방향이 같을수록 1

자카드 계수

$$J(A, B) = |A \cap B| \,/\, |A \cup B|$$

{사과, 딸기}와 {사과, 딸기, 바나나} → 2/3

POINT 1

거리가 곧 유사도

군집화는 가까운 데이터를 같은 군집으로 묶음.

따라서 어떤 거리를 쓰는지에 따라 군집화 결과가 달라질 수 있음.

POINT 2

거리의 세 갈래

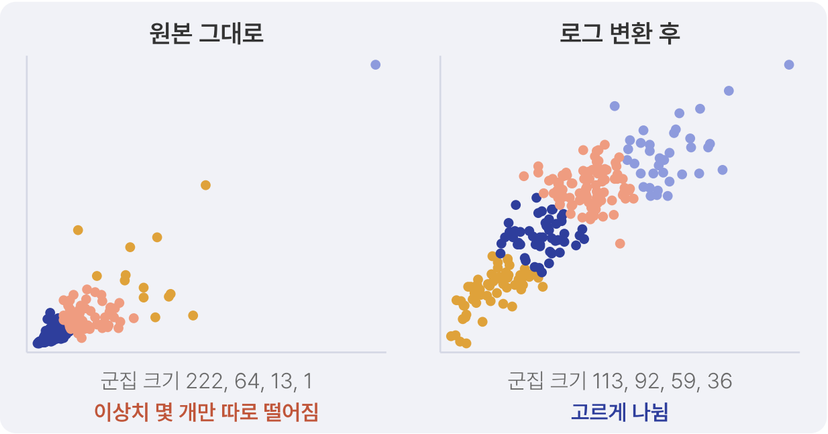
수학적 거리(유클리드, 맨해튼, 민코프스키)는 좌표 차이로 계산함.

마할라노비스는 변수 사이 상관까지 반영하는 통계적 거리임.

방향이 중요하면 코사인 유사도, 집합 데이터에는 자카드 계수를 씀.

데이터 조정

치우친 데이터에 K-means를 적용하면



두 가지 조정 방법

스케일링 (StandardScaler)

$$z = (x - \mu) / \sigma$$

μ 평균, σ 표준편차
모든 변수를 평균 0, 표준편차 1로

로그 변환 (np.log1p)

$$x' = \log(1 + x)$$

큰 값일수록 더 많이 줄어듦
긴 꼬리를 줄여 분포를 고르게

POINT 1

왜 조정해야 하나

치우친 데이터에 K-means를 쓰면 중심이 이상치 쪽으로 끌려감. 그 결과 이상치 몇 개만으로 된 작은 군집이 생기고 나머지는 하나로 뭉침.

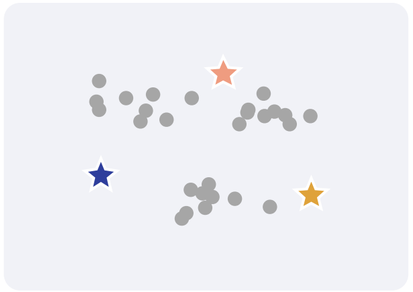
POINT 2

스케일링과 로그 변환

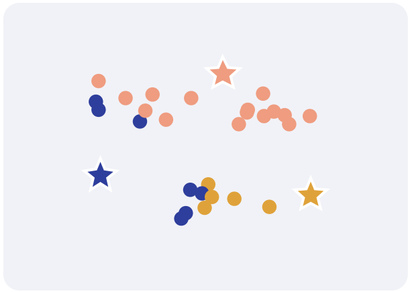
단위가 큰 변수가 거리를 좌우하지 않게 StandardScaler로 z = (x − μ) / σ 변환을 함. 꼬리가 긴 변수는 np.log1p, 즉 log(1 + x)로 큰 값을 압축함.

K-means 작동 원리

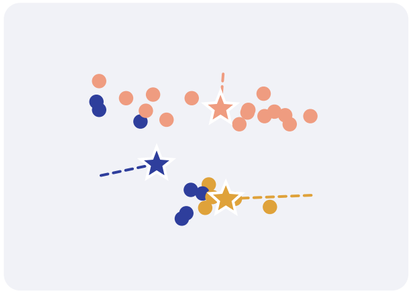
1. 중심 임의 선택



2. 가까운 중심에 할당



3. 평균으로 중심 이동



4. 변화가 없으면 종료



목적 함수 (이너셔, SSE)

$$J = \sum_{k=1}^{K} \sum_{x \in C_k} \|x - \mu_k\|^2$$

★ μ_k: 군집 k의 중심

J가 줄어드는 방향으로
할당과 이동을 반복함

POINT 1

할당과 이동 반복

K-means는 각 군집을 중심점(centroid) 하나로 대표하는 알고리즘임.

각 점을 가장 가까운 중심에 할당하고 군집의 평균으로 중심을 옮기는 과정을,

중심이 변하지 않을 때까지 반복함.

POINT 2

이너셔로 평가

이너셔는 각 점과 소속 군집 중심 사이의 거리 제곱을 모두 더한 값(SSE)임.

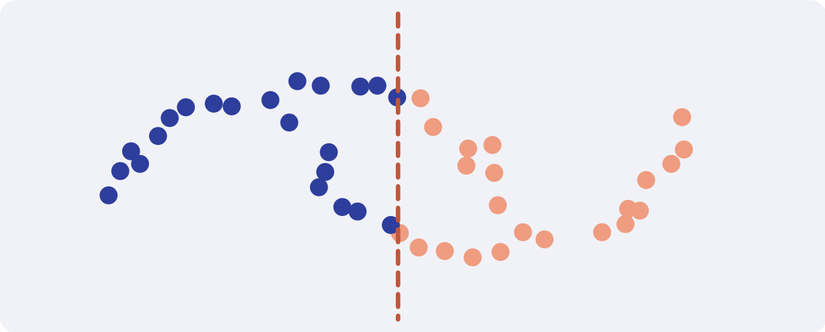
반복할수록 이 값이 줄며, 낮을수록 점들이 중심에 촘촘히 모인 것임.

K-means 한계점

실제 구조



K-means 결과



직선으로 잘려 엉뚱하게 나뉨

POINT 1

장점

구조가 단순하고 계산이 빨라서 계층 군집보다 큰 데이터를 효율적으로 처리함.

데이터 구조에 대한 사전 정보 없이도 바로 적용할 수 있어 범용성이 높음.

POINT 2

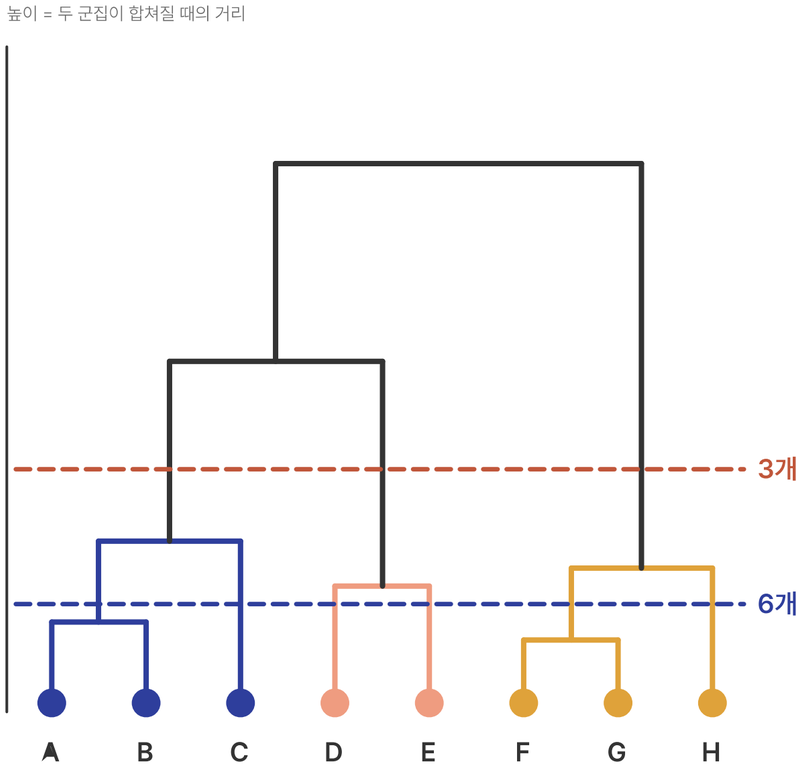
한계와 대안

K를 미리 정해야 하고 초기 중심에 따라 결과가 달라져 여러 번 초기화해야 함.

평균을 쓰므로 이상치에 민감하고 둥글지 않은 군집은 잘 못 찾음.

이상치가 많으면 K-medoids, 타원형 분포면 GMM을 고려함.

계층 군집



높이 h에서 자르면 만나는 세로선 수 = 군집 수

POINT 1

병합 과정

처음에는 데이터 하나하나를 군집으로 보고, 가장 가까운 두 군집을 계속 합쳐 하나가 될 때까지 반복함.

이 병합 과정을 나무 모양으로 그린 것이 덴드로그램이며, K를 미리 정하지 않아도 됨.

POINT 2

덴드로그램 자르기

세로축 높이는 두 군집이 합쳐질 때의 거리임. 높이 h에서 가로선을 그으면 만나는 세로선 수가 곧 군집 수임.

다만 계산량이 약 $O(n^2)$으로 크고, 한 번 합친 군집은 되돌릴 수 없음.

연결 방법

Single 가장 가까운 두 점

$$\min_{a \in A,\ b \in B} d(a, b)$$



Complete 가장 먼 두 점

$$\max_{a \in A,\ b \in B} d(a, b)$$



Average 모든 점 쌍의 평균

$$\text{mean}_{a \in A,\ b \in B}\ d(a, b)$$



Ward 합쳤을 때 제곱합 증가량

$$SSE_{A \cup B} - SSE_A - SSE_B$$



POINT 1

군집 사이 거리

Single은 가장 가까운 두 점,

Complete는 가장 먼 두 점,

Average는 모든 점 쌍의 평균 거리를 군집 사이 거리로 씀.

Ward는 합쳤을 때 군집 안 제곱합이 가장 적게 늘어나는 쌍을 합침.

POINT 2

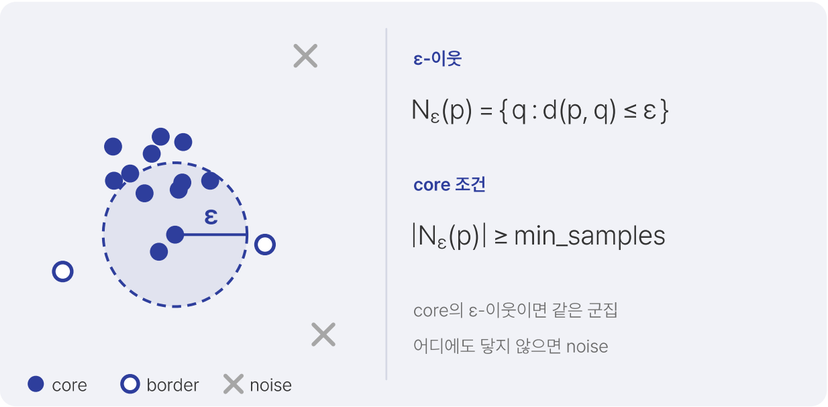
연결 방법 고르기

Single은 길게 이어진 군집을 잘 찾지만 잡음에 약하고,

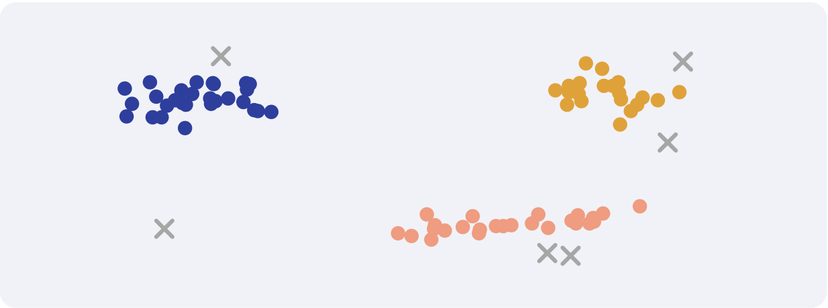
Ward는 크기가 비슷한 둥근 군집을 만드는 경향이 있음.

거리 함수에 따라서도 결과가 달라지므로 여러 조합을 비교해 보는 것이 좋음.

DBSCAN



적용 예시: 가상의 주택 좌표



eps = 0.8, min_samples = 5 → 구역 3개, 외딴 집(noise) 6채

POINT 1

작동 방식

반경 eps 안에 이웃이 min_samples개 이상이면 core로 보고,

core끼리 이어 군집을 만듦.

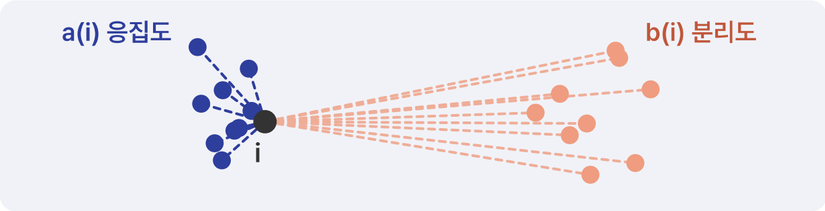
core의 이웃이지만 core가 아니면 border, 어디에도 속하지 않으면 noise임.

POINT 2

적용 예시와 장단점

가상의 주택 좌표에 적용하면 모여 있는 구역은 군집으로 묶고 외딴 집은 noise로 분리함. 군집 수를 정하지 않아도 되지만, 군집마다 밀도 차이가 크면 모든 군집을 찾기 어려움.

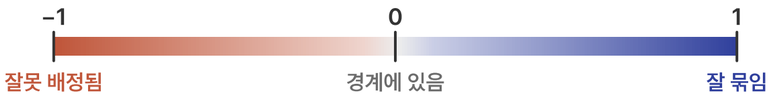
실루엣 계수

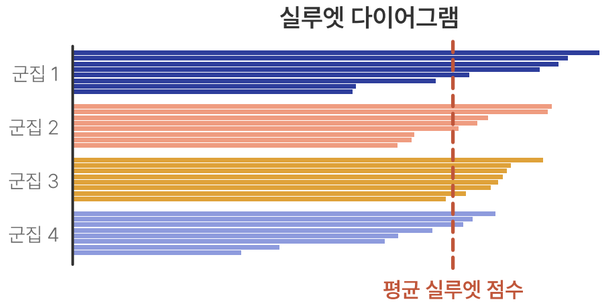


$a(i) = \text{mean}_{j \in C_i,\ j \neq i}\ d(i, j)$

$b(i) = \min_{C \neq C_i} \text{mean}_{j \in C}\ d(i, j)$

$s(i) = (b(i) - a(i)) \ / \ \max(a(i), b(i))$





POINT 1

계산 방법

정답이 없는 군집화는 결과를 따로 평가할 지표가 필요함.

a(i)는 같은 군집 안 평균 거리(응집도)

b(i)는 가장 가까운 다른 군집까지의 평균 거리(분리도)임.

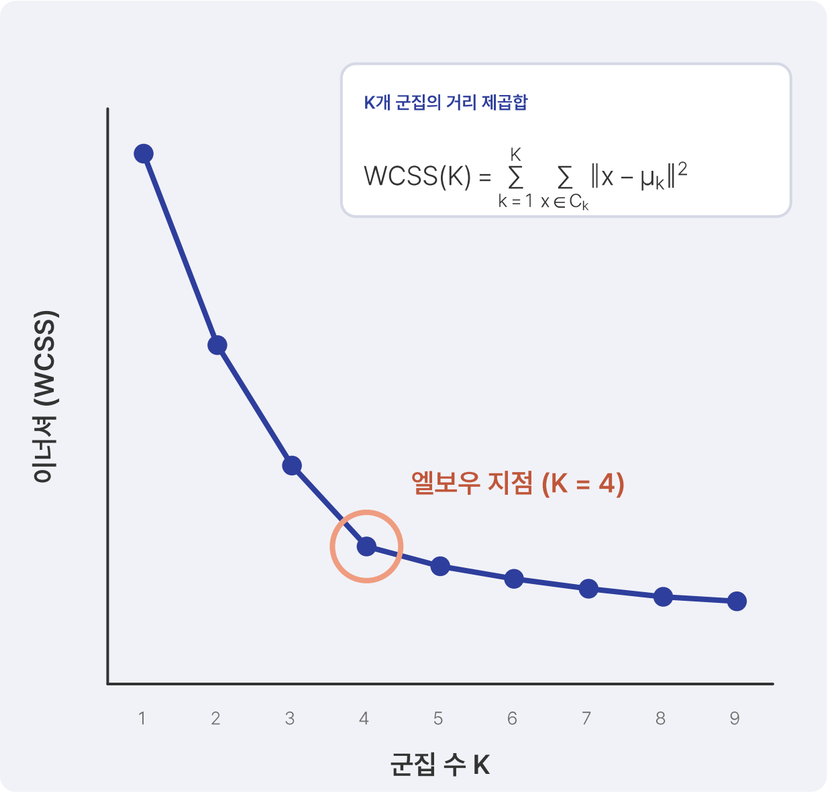
POINT 2

해석과 다이어그램

1에 가까우면 잘 묶인 것, 0 근처면 경계에 있는 것, 음수면 잘못 배정된 것임.

전체 점수는 모든 점의 s(i) 평균이며, 막대가 평균선을 넘고 두께가 비슷하면 적절한 K로 봄.

최적의 K 찾기



꺾이는 지점 이후로는 줄어드는 폭이 작음

POINT 1

엘보우 방법

K를 늘려 가며 이너셔(WCSS)를 그리고,

감소 폭이 갑자기 작아지는 꺾이는 지점을 K로 고름.

실루엣 점수가 가장 높은 K와 함께 비교하면 더 안전함.

POINT 2

그 밖의 기준

데이터 수가 n일 때 $\sqrt{\frac{n}{2}}$ 개로 정하는 경험 법칙이 있음.

덴드로그램을 보거나 GMM의 정보 기준(AIC, BIC)으로 정하기도 함.

알고리즘 한눈에 비교

CENTER



K-means

K를 미리 정해야 하며 둥근 군집을 잘 찾음. 대용량 데이터도 빠르게 처리함.

TREE



계층 군집

K 없이 덴드로그램으로 군집 수를 정함. 데이터가 많으면 느려짐.

DENSITY



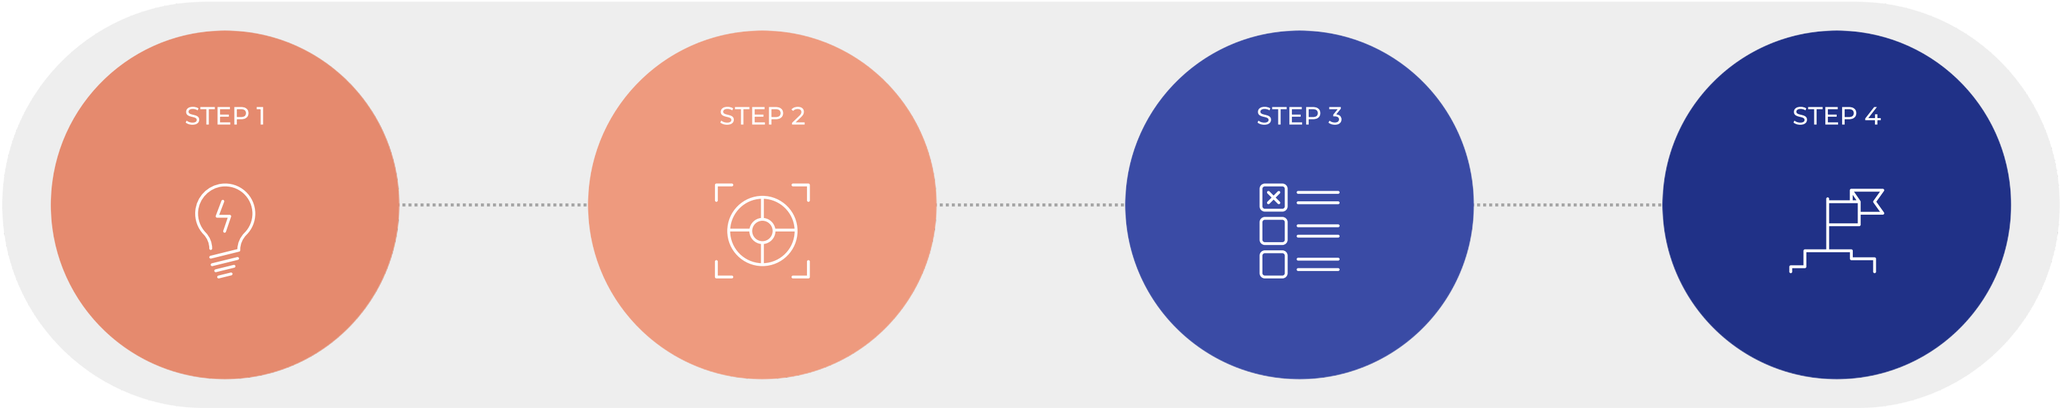
DBSCAN

K 없이 자유로운 모양의 군집과 noise를 찾음. 밀도 차이가 크면 약함.

데이터의 모양과 크기를 보고 알고리즘을 고름

결과는 실루엣 점수와 엘보우 그래프로 확인하고, 여러 알고리즘을 비교해 보는 것이 좋음.

군집화 분석 흐름



전처리

결측치를 처리하고
변수의 스케일을 맞춤.

K 정하기

엘보우 그래프와
실루엣 점수로 적절한 군집 수를 고름.

모델 학습

K-means, 계층 군집, DBSCAN
모델을 학습시켜 군집 라벨을 얻음.

결과 해석

군집별 평균을 비교하고
각 군집에 의미 있는 이름을 붙임.